Mymeningh Rainfall Classification using KNN Algorithm

```
In [1]:
,, ,, ,,
@author: Manoj Roy, ID: 20216039"""
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
from sklearn.model selection import train test split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy score
from sklearn.metrics import classification report, confusion matrix
In [2]:
#read data
df=pd.read csv('Mymensingh.csv')
df.head()
Out[2]:
  ID
         Station Year Month TEM DPT WIS HUM
                                              SLP T_RAN A_RAIN RAN
  1 Mymensingh 1960
                        1 16.9 11.3
                                   2.0 73.39 1016.0
                                                          0.48 NRT
   2 Mymensingh 1960
                        2 21.4 12.6
                                   1.7 66.34 1013.0
                                                      0
                                                          0.00 NRT
2 3 Mymensingh 1960
                        3 24.1 14.9 2.3 64.13 1011.4
                                                          2.23 LTR
                        4 29.9 17.6
                                   2.2 59.03 1007.1
                                                     27
                                                          0.90 NRT
  4 Mymensingh 1960
  5 Mymensingh 1960
                        5 29.6 23.2 2.4 73.45 1003.4
                                                    187
                                                          6.03 LTR
In [3]:
#predict class
Y=df['RAN']
In [4]:
#removing unnecessary columns
del df["ID"]
del df["Station"]
del df['Year']
del df['Month']
del df['RAN']
In [5]:
df.shape
Out[5]:
(672, 7)
In [6]:
df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 672 entries, 0 to 671
Data columns (total 7 columns):
 # Column Non-Null Count Dtype
    -----
   TEM
 0
            654 non-null
                            float64
```

DPT

1

657 non-null

float64

```
672 non-null
     WIS
                                iloat64
     HUM
              654 non-null
                                float64
 4
     SLP
              654 non-null
                                float64
 5
     T RAN
              672 non-null
                                int64
     A RAIN 672 non-null
 6
                                float64
dtypes: float64(6), int64(1)
memory usage: 36.9 KB
In [7]:
#Full missing values
df['TEM'] = df['TEM'].fillna(df['TEM'].mean())
df['DPT'] = df['DPT'].fillna(df['DPT'].mean())
df['HUM'] = df['HUM'].fillna(df['HUM'].mean())
df['SLP'] = df['SLP'].fillna(df['SLP'].mean())
In [8]:
#feauture class
X=df
X.head()
Out[8]:
  TEM DPT WIS HUM
                        SLP T_RAN A_RAIN
  16.9 11.3
             2.0 73.39 1016.0
                                      0.48
1 21.4 12.6
             1.7 66.34 1013.0
                                 0
                                      0.00
2 24.1 14.9
            2.3 64.13 1011.4
                                      2.23
3 29.9 17.6 2.2 59.03 1007.1
                                27
                                      0.90
   29.6 23.2 2.4 73.45 1003.4
                                      6.03
In [9]:
df.isnull
Out[9]:
<bound method DataFrame.isnull of</pre>
                                             TEM
                                                    DPT WIS
                                                                 HUM
                                                                           SLP T RAN A RAIN
   16.9 11.3 2.0 73.39 1016.0
                                             15
                                                    0.48
                                                    0.00
1
     21.4 12.6 1.7 66.34 1013.0
                                             Ω
2
     24.1 14.9 2.3 64.13 1011.4
                                             69
                                                    2.23
3
     29.9 17.6 2.2
                        59.03 1007.1
                                             27
                                                    0.90
     29.6 23.2 2.4
                       73.45 1003.4
                                            187
                                                    6.03
      . . .
             . . .
                   . . .
                                                     . . .
                                            . . .
                        87.10 1003.3
667
    28.7
            26.2
                  2.5
                                            349
                                                   11.26
    28.8 25.2 2.0
                        85.63 1006.0
                                            263
                                                   8.77
668
669 27.0 23.5 2.0 82.48 1011.3
                                            180
                                                    5.81
670 23.1 18.7 1.7 81.73 1013.7
                                                    0.43
                                            13
    18.3 14.9 1.8 82.68 1015.9
671
                                             5
                                                    0.16
[672 \text{ rows x 7 columns}] >
In [10]:
#splitting the dataset
#assuming initial k value to be 15
X train, X test, Y train, Y test=train test split(X, Y, test size=0.25, random state=216
KNN=KNeighborsClassifier(n neighbors=3,metric='euclidean')
KNN.fit(X train, Y train)
P=KNN.predict(X test)
Р
Out[10]:
array(['MHR', 'MHR', 'NRT', 'MHR', 'LTR', 'NRT', 'NRT', 'LTR', 'LTR',
        'NRT', 'NRT', 'LTR', 'MHR', 'NRT', 'NRT', 'LTR', 'MHR', 'LTR', 'NRT', 'NRT', 'NRT', 'NRT', 'NRT', 'LTR', 'MHR', 'NRT', 'NRT', 'NRT', 'LTR', 'LTR', 'MHR', 'NRT', 'NRT', 'NRT', 'LTR', 'LTR', 'LTR', 'LTR', 'MHR',
```

```
'LTR', 'NRT', 'LTR', 'NRT', 'MHR', 'NRT', 'NRT', 'LTR', 'NRT',
      'NRT', 'LTR', 'NRT', 'NRT', 'NRT', 'MHR', 'LTR', 'MHR',
      'NRT', 'NRT', 'MHR', 'NRT', 'LTR', 'LTR', 'NRT', 'MHR',
      'MHR', 'LTR', 'LTR', 'MHR', 'LTR', 'LTR', 'NRT', 'MHR',
      'NRT', 'MHR', 'MHR', 'NRT', 'LTR', 'NRT', 'LTR', 'LTR', 'NRT',
      'LTR', 'LTR', 'MHR', 'NRT', 'MHR', 'LTR', 'NRT', 'MHR',
      'LTR', 'LTR', 'MHR', 'LTR', 'NRT', 'LTR', 'NRT', 'NRT', 'NRT',
      'NRT', 'LTR', 'NRT', 'LTR', 'LTR', 'NRT', 'LTR', 'NRT', 'MHR',
      'NRT', 'MHR', 'NRT', 'NRT', 'MHR', 'NRT', 'MHR', 'NRT', 'MHR',
      'LTR', 'NRT', 'NRT', 'NRT', 'NRT', 'NRT', 'LTR', 'MHR',
      'MHR', 'NRT', 'NRT', 'NRT', 'LTR', 'MHR', 'LTR', 'LTR',
      'MHR', 'MHR', 'LTR', 'LTR', 'MHR', 'MHR', 'NRT', 'NRT', 'LTR',
      'NRT', 'NRT', 'LTR', 'NRT', 'MHR', 'MHR', 'NRT', 'LTR', 'MHR',
      'MHR', 'LTR', 'NRT', 'MHR', 'NRT', 'MHR', 'MHR', 'LTR', 'MHR', 'LTR', 'LTR', 'LTR', 'LTR', 'NRT'], dtype=object)
In [11]:
accuracy score(Y test, P)
Out[11]:
In [12]:
# Optimal Value of k and Accuracy Rate for Optimal k
error = []
accuracy = []
# Calculating error for K values between 1 and 40
for i in range (1, 40):
   knn = KNeighborsClassifier(n neighbors=i,metric='euclidean')
   knn.fit(X train, Y train)
   pred i = knn.predict(X test)
   error.append(np.mean(pred i != Y test))
   accuracy.append(np.mean(pred i == Y test))
print(error)
print(accuracy)
952380952380952, 0.0, 0.005952380952380952, 0.005952380952, 0.005952380952380952, 0
.005952380952380952,\ 0.005952380952380952,\ 0.005952380952380952]
76190476191, 1.0, 0.9940476190476191, 0.9940476190476191, 0.9940476190476191, 0.994047619
0476191, 0.9940476190476191, 0.9940476190476191]
In [13]:
#plotting the optimal value of k vs Error Rate
plt.figure(figsize=(9, 5))
plt.plot(range(1, 40), error, color='red', linestyle='solid', marker='o',
        linewidth =2, markerfacecolor='blue', markersize=10)
plt.title('Optimal value of k')
plt.xlabel('Value of k')
plt.ylabel('Error Rate')
plt.savefig('ErrorRateMN.jpg',dpi=1200)
                         Optimal value of k
  0.006
                                                00000
  0.005
```

1.0

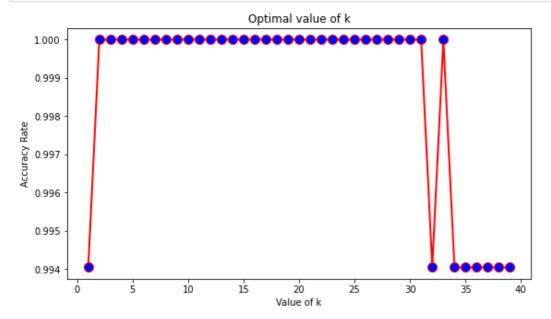
0.004

0.003

0.002

```
0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000 - 0.000
```

In [14]:



In [15]:

Out[15]:

```
array(['MHR', 'MHR', 'NRT', 'MHR', 'LTR', 'NRT', 'NRT', 'LTR', 'LTR',
             'NRT', 'LTR', 'MHR', 'NRT', 'NRT',
                                                'LTR', 'MHR',
       'NRT',
                                                                'LTR',
       'NRT',
                           'NRT', 'MHR', 'NRT', 'LTR', 'LTR', 'LTR', 'LTR', 'LTR', 'LTR', 'LTR', 'LTR',
             'NRT', 'NRT',
                           'NRT',
                                                               'MHR',
             'NRT', 'MHR',
                                                               'MHR',
       'NRT',
       'LTR', 'NRT', 'LTR', 'NRT', 'MHR', 'NRT', 'NRT', 'LTR',
                                                               'NRT',
       'NRT', 'LTR', 'NRT', 'NRT', 'NRT', 'MHR', 'LTR',
                                                               'MHR',
       'NRT', 'NRT', 'MHR', 'NRT', 'LTR', 'LTR', 'NRT', 'MHR',
       'MHR', 'LTR', 'LTR', 'MHR', 'LTR', 'LTR', 'NRT', 'MHR',
       'NRT', 'MHR', 'MHR', 'NRT', 'LTR', 'NRT', 'LTR', 'LTR', 'NRT',
       'LTR', 'LTR', 'MHR', 'NRT', 'MHR', 'LTR', 'NRT', 'MHR',
       'LTR', 'LTR', 'MHR', 'LTR', 'NRT', 'LTR', 'NRT', 'NRT', 'NRT',
       'NRT', 'LTR', 'NRT', 'LTR', 'NRT', 'LTR', 'NRT', 'MHR',
       'NRT', 'MHR', 'NRT', 'NRT', 'MHR', 'NRT', 'MHR', 'NRT', 'MHR',
       'LTR', 'NRT', 'NRT', 'NRT', 'NRT', 'NRT', 'LTR', 'MHR',
       'MHR', 'NRT', 'NRT', 'NRT', 'LTR', 'MHR', 'LTR', 'LTR',
       'MHR', 'MHR', 'LTR', 'LTR', 'MHR', 'MHR', 'NRT', 'NRT', 'LTR',
       'NRT', 'NRT', 'LTR', 'NRT', 'MHR', 'MHR', 'NRT', 'LTR', 'MHR',
       'MHR', 'LTR', 'NRT', 'MHR', 'NRT', 'MHR', 'MHR', 'MHR', 'LTR',
       'MHR', 'LTR', 'NRT', 'LTR', 'LTR', 'NRT'], dtype=object)
```

```
In [16]:
accuracy_score(Y_test, P1)
Out[16]:
1.0
In [17]:
print(confusion matrix(Y test, P1))
[[54 0 0]
[ 0 46 0]
 [ 0 0 68]]
In [18]:
print(classification_report(Y_test, P1))
              precision recall f1-score
                                              support
                   1.00
                             1.00
                                       1.00
                                                    54
         LTR
                                       1.00
                                                    46
         MHR
                   1.00
                             1.00
                                       1.00
         NRT
                   1.00
                             1.00
                                                    68
   accuracy
                                       1.00
                                                  168
                   1.00
                             1.00
                                       1.00
                                                  168
   macro avg
                             1.00
                                       1.00
                                                  168
weighted avg
                   1.00
```

#Inference Here, I initially set the K value 3. Where I found the accuracy score of the classification 1. After iterating it 40 times, Here I found multiple optimal k values(3-31,33). I chose 5 among them, for which the accuracy score remained the same. From this assignment, I came to know about the optimal K value identification process & necessity.